

1(a) Mixture Importance Sampling for Up-and-In Call

本題使用 mixture importance sampling 定價 up-and-in call option，其 payoff 為：

$$e^{-rT}(S_T - K)^+ \mathbf{1}_{\max_{t \leq T} S_t \geq L}$$

也就是只有當股價路徑曾經碰到 barrier level L 時，選擇權才會被啟動；若沒有碰到 barrier，payoff 為 0。

由於當 barrier 較高時，普通 Monte Carlo 不容易模擬到碰到 barrier 的路徑，因此 payoff 大多為 0，容易造成估計變異數偏大。因此本題使用 importance sampling，透過改變 drift，使股價更容易往上碰到 barrier，再利用 likelihood ratio 修正抽樣分配改變造成的偏誤。

題目定義：

$$\theta = -\frac{1}{T} \ln \left(\frac{S_0}{L} \right)$$

並使用四個不同的 drift：

$$\theta_1 = 0, \theta_2 = 0.5\theta, \theta_3 = \theta, \theta_4 = 1.5\theta$$

本次 mixture weights 原本設定為：

$$(0.25, 0.25, 0.25, 0.25)$$

但測試後發現 standard deviation 約為 0.3045，因此後續改為：

$$(0.2, 0.3, 0.3, 0.2)$$

降低 θ_1 與 θ_4 的權重，提高中間 drift 的權重。修改後 standard deviation 約降為 0.2963，代表估計結果略為穩定。

模擬結果如下：

Method	Price	Standard Deviation	Standard Error	Hit Ratio
Mixture IS	0.2087	0.2963	0.000937	0.4449

結果顯示，importance sampling 能有效增加碰到 barrier 的路徑數，並得到穩定

的 up-and-in call 價格估計。

1(b) Comparison between Mixture IS and Single Theta IS

```
✓ 2m 39.0s Python

===== 1(a) Mixture Importance Sampling =====
theta : 2.187858681527455
theta_list : [0.          1.09392934  2.18785868  3.28178802]
omega_equal : [0.25  0.25  0.25  0.25]
omega_used : [0.2  0.3  0.3  0.2]
price : 0.20868448422130936
standard_deviation : 0.2963345418310414
standard_error : 0.0009370921015685342
95% CI : (np.float64(0.20684778370223503), np.float64(0.2105211847403837))
hit_ratio : 0.44492

===== 1(b) Single Theta Importance Sampling =====
theta : 2.187858681527455
price : 0.20991249581903798
standard_deviation : 0.23312533845021044
standard_error : 0.0007372070498002929
95% CI : (np.float64(0.2084675700014294), np.float64(0.21135742163664656))
hit_ratio : 0.58038

===== Comparison =====
Mixture IS price: 0.20868448422130936
Single theta IS price: 0.20991249581903798
Mixture IS standard deviation: 0.2963345418310414
Single theta IS standard deviation: 0.23312533845021044
Mixture IS standard error: 0.0009370921015685342
Single theta IS standard error: 0.0007372070498002929
```

1(b) 要求比較 **mixture importance sampling** 與只使用單一 θ 的 importance sampling 所得到的 standard deviation。

在第 1(a) 中，mixture importance sampling 使用四個不同的 drift：

$$\theta_1 = 0, \theta_2 = 0.5\theta, \theta_3 = \theta, \theta_4 = 1.5\theta$$

並設定 mixture weights 為：

$$(\omega_1, \omega_2, \omega_3, \omega_4) = (0.2, 0.3, 0.3, 0.2)$$

而第 1(b) 的 single theta importance sampling 則只使用：

$$\theta_3 = \theta$$

也就是每一條模擬路徑都在同一個 drift θ 下產生。

模擬結果比較

本次模擬得到以下結果：

Method	Price	Standard Deviation	Standard Error	Hit Ratio
Mixture IS	0.2087	0.2963	0.000937	0.4449
Single θ IS	0.2099	0.2331	0.000737	0.5804

從 price 來看，兩種方法的估計值非常接近：

$$0.2087 \approx 0.2099$$

這表示兩種方法在 likelihood ratio 修正後，都能得到相近的 up-and-in call fair price。

Standard Deviation 的比較

本題主要要求比較 standard deviation。根據模擬結果：

$$SD_{\text{Mixture IS}} = 0.2963$$

$$SD_{\text{Single } \theta \text{ IS}} = 0.2331$$

因此：

$$SD_{\text{Single } \theta \text{ IS}} < SD_{\text{Mixture IS}}$$

也就是說，在本組參數下，只使用單一 θ 的 importance sampling 反而有較低的 standard deviation。

Single θ IS 比較好

本題中的：

$$\theta = -\frac{1}{T} \ln \left(\frac{S_0}{L} \right) = \frac{1}{T} \ln \left(\frac{L}{S_0} \right)$$

其意義是：若先忽略隨機波動，使用這個 drift 可以使股價平均大約從 S_0 上升到 barrier level L 。

也就是說， θ 本身就是針對 barrier hitting event 所設計的 drift，因此它已經能有效提高：

$$P(\max S_t \geq L)$$

從結果來看，single theta IS 的 hit ratio 為：

$$0.5804$$

高於 mixture IS 的：

$$0.4449$$

代表 single theta IS 在本組參數下產生了更多碰到 barrier 的路徑，因此有效樣本較多。

Mixture IS 沒有降低 standard deviation

Mixture IS 的優點是混合多個不同 drift，避免過度依賴單一 sampling distribution。但在本題設定下，mixture 中的有些 drift 可能反而降低效率。

例如：

$$\theta_1 = 0$$

較保守，股價不容易往上碰到 barrier，因此可能產生較多 payoff 為 0 的路徑。

而：

$$\theta_4 = 1.5\theta$$

雖然能讓股價更容易碰到 barrier，但 drift 過大時，likelihood ratio 可能波動較大，反而增加估計變異數。

因此，即使我將 mixture weights 從原本的等權重：

$$(0.25, 0.25, 0.25, 0.25)$$

調整為：

$$(0.2, 0.3, 0.3, 0.2)$$

以降低兩端 drift 的影響，mixture IS 的 standard deviation 仍然高於 single theta IS。不過，相較於原本等權重設定下的 standard deviation 約為 0.3045，調整後的 standard deviation 降為 0.2963，表示此權重調整仍有稍微改善 mixture IS 的表現。

結論

本次比較結果顯示，mixture importance sampling 與 single theta importance sampling 得到的價格相近，代表兩者在 likelihood ratio 修正後都能估計 up-and-in call 的 fair price。

然而，以 standard deviation 作為比較標準時，本組參數下 single theta importance sampling 表現較佳：

$$0.2331 < 0.2963$$

可能原因是 θ 本身已經能有效將股價路徑推向 barrier，因此比混合多個 drift 的方法更集中、更有效。Mixture IS 雖然理論上能提高抽樣分配的穩健性，但若其中包含較不適合的 drift，仍可能導致 standard deviation 較高。

2. Pricing an Up-and-In Call Using Moon's Algorithm

```
✓ 59.5s Python
==== 2. Moon's Algorithm for Up-and-In Call ====
price : 0.2158233236186866
standard_deviation : 0.6742748444460457
standard_error : 0.002132244277405239
95% CI : (np.float64(0.21164412483497236), np.float64(0.22000252240240087))
hit_ratio : 0.10731
```

使用 Moon's algorithm 定價 up-and-in call option。Up-and-in call 的 payoff 為：

$$e^{-rT}(S_T - K)^+ \mathbf{1}_{\max_{0 \leq t \leq T} S_t \geq L}$$

也就是只有當股價路徑在到期前曾經碰到 barrier level L 時，選擇權才會被啟動；若股價從未碰到 barrier，則 payoff 為 0。

一般 Monte Carlo 模擬 barrier option 時，只會檢查離散時間點上的股價是否超過 barrier。然而，股價在 Black-Scholes model 中是連續變動的，因此即使兩個相鄰時間點的股價都低於 L ，股價仍可能在兩點之間曾經碰到 barrier。Moon's algorithm 的主要目的，就是利用 Brownian bridge 的概念修正這個問題。

本題在風險中立測度下模擬股價路徑：

$$S_{t+\Delta t} = S_t \exp \left[\left(r - \frac{1}{2} \sigma^2 \right) \Delta t + \sigma \sqrt{\Delta t} Z \right]$$

其中：

$$Z \sim N(0,1)$$

若 $S_t \geq L$ 或 $S_{t+\Delta t} \geq L$ ，則直接判定該路徑已經碰到 barrier。若兩個端點皆小於 L ，則使用 Brownian bridge 計算兩點之間碰到 barrier 的機率：

$$P(hit) = \exp \left[-\frac{2(L - S_t)(L - S_{t+\Delta t})}{\sigma^2 S_t^2 \Delta t} \right]$$

接著產生一個 uniform random variable：

$$U \sim U(0,1)$$

若：

$$U < P(hit)$$

則判定股價在兩個時間點之間曾經碰到 barrier，並將該路徑標記為 knocked-in。

本次模擬使用參數：

$$S_0 = 10, K = 10, L = 12, r = 0.04, \sigma = 0.4, T = \frac{1}{12}$$

模擬路徑數為：

$$100000$$

時間切割數為：

$$252$$

模擬結果如下：

Method	Price	Standard Deviation	Standard Error	95% CI	Hit Ratio
Moon's Algorithm	0.2158	0.6743	0.00213	[0.2116, 0.2200]	0.1073

由結果可知，Moon's algorithm 得到的 up-and-in call price 約為 0.2158。Hit ratio 約為 0.1073，表示約 10.7% 的模擬路徑被判定曾經碰到 barrier。由於本題使用原本 risk-neutral drift 進行模擬，沒有像 importance sampling 一樣刻意提高股價

往上碰到 barrier 的機率，因此 hit ratio 較低是合理的。

此外，Moon's algorithm 會考慮兩個離散時間點之間可能發生的 barrier crossing，因此相較於只檢查離散股價點的普通 Monte Carlo，更適合用來定價 barrier option。

3. Pricing an Asian Call Option Using the Control Variate Method

```
✓ 29.3s Python
==== 3. Asian Call with Control Variate ====
ordinary_MC_price : 0.27314074102003344
ordinary_MC_sd : 0.41270409586804546
ordinary_MC_se : 0.0013050849426235092
ordinary_MC_95% CI : (np.float64(0.27058277453249135), np.float64(0.2756987075075755))
geometric_asian_price : 0.2678795214544776
theta_star : 1.0184184187885998
control_variate_price : 0.2736437652891221
control_variate_sd : 0.00621591432005544
control_variate_se : 1.9656446991832037e-05
control_variate_95% CI : (np.float64(0.2736052386530181), np.float64(0.2736822919252261))
```

本題欲定價的是 arithmetic average Asian call，其 discounted payoff 為：

$$X = e^{-rT} \max(\bar{S}_A - K, 0)$$

其中：

$$\bar{S}_A = \frac{1}{N} \sum_{i=1}^N S(t_i)$$

為模擬路徑上的 arithmetic average stock price。

由於 arithmetic average Asian call 一般沒有簡單 closed-form solution，因此本題使用 Monte Carlo simulation 進行估計。

Control Variate 的選擇

本題選擇 **geometric average Asian call** 作為 control variate。其 discounted payoff 為：

$$Y = e^{-rT} \max(\bar{S}_G - K, 0)$$

其中：

$$\bar{S}_G = \left(\prod_{i=1}^N S(t_i) \right)^{1/N} = \exp \left(\frac{1}{N} \sum_{i=1}^N \ln S(t_i) \right)$$

選擇 geometric average Asian call 的原因是：

1. 與 arithmetic average Asian call payoff 高度相關；
2. geometric average Asian call 具有 closed-form price。

因此使用：

$$X_{CV} = X + \theta(E[Y] - Y)$$

作為 control variate estimator，其中：

$$\theta^* = \frac{\text{Cov}(X, Y)}{\text{Var}(Y)}$$

Geometric Average Asian Call Price

根據講義中的公式：

$$C_G = S_0 e^{-\left(\frac{r}{2} + \frac{\sigma^2}{12}\right)T} N(d_1) - K e^{-rT} N(d_2)$$

其中：

$$d_1 = \frac{\ln(S_0/K) + \frac{1}{2}\left(r + \frac{\sigma^2}{6}\right)T}{\sigma\sqrt{T/3}}$$

$$d_2 = d_1 - \sigma\sqrt{T/3}$$

因此在程式中，先計算 $C_G = E[Y]$ ，再將其代入 control variate estimator。

Simulation Setting

本題使用以下參數：

$$S_0 = 10, K = 10, r = 0.04, \sigma = 0.4, T = \frac{1}{12}$$

模擬路徑數：

100000

時間切割數：

252

股價路徑在 risk-neutral measure 下模擬：

$$S_{t+\Delta t} = S_t \exp \left[\left(r - \frac{1}{2} \sigma^2 \right) \Delta t + \sigma \sqrt{\Delta t} Z \right]$$

其中：

$$Z \sim N(0,1)$$

95% Confidence Interval

對 estimator：

$$\hat{C}_{CV} = \frac{1}{M} \sum_{j=1}^M X_{CV,j}$$

standard error 為：

$$SE = \frac{s_{CV}}{\sqrt{M}}$$

其中 s_{CV} 為 control variate estimator 的樣本標準差。

因此 95% confidence interval 為：

$$\left[\hat{C}_{CV} - 1.96 \frac{s_{CV}}{\sqrt{M}}, \hat{C}_{CV} + 1.96 \frac{s_{CV}}{\sqrt{M}} \right]$$

Simulation Results

執行程式後，可將結果整理如下：

Method	Price	Standard Deviation	Standard Error	95% CI
Ordinary MC	0.2731	0.4127	0.001305	[0.2706, 0.2757]
Control Variate	0.2736	0.0062	0.0000197	[0.2736, 0.2737]

另可列出：

Item	Value
Geometric Asian Call Price	0.2679
θ^*	1.0184

Result Analysis

從結果可以觀察到：

普通 Monte Carlo 的 standard deviation 為：

$$0.4127$$

而 control variate estimator 的 standard deviation 為：

$$0.0062$$

因此：

$$0.0062 \ll 0.4127$$

表示 control variate method 非常有效地降低了估計變異數。

此外，standard error 也從：

$$0.001305$$

大幅下降至：

$$0.0000197$$

因此 95% confidence interval 明顯變窄：

普通 Monte Carlo：

$$[0.2706, 0.2757]$$

Control Variate：

$$[0.2736, 0.2737]$$

這代表 control variate estimator 的估計更加穩定。

造成 variance reduction 效果顯著的主要原因是：

- arithmetic average Asian call payoff
- geometric average Asian call payoff

兩者具有非常高的相關性，因此：

$$E[Y] - Y$$

可以有效修正 arithmetic Asian payoff 的共同波動。

此外，本次估計出的：

$$\theta^* \approx 1.0184$$

接近 1，也表示 geometric average Asian call 與 arithmetic average Asian call 的 payoff 幾乎呈現一對一的線性關係，因此 control variate method 能夠有效降低 variance。

Conclusion

本題使用 Monte Carlo simulation 定價 arithmetic average Asian call，並以 geometric average Asian call 作為 control variate。由於 geometric average Asian call 與 arithmetic average Asian call 的 payoff 高度相關，且 geometric average Asian call 具有 closed-form price，因此可用來修正 arithmetic Asian call 的 Monte Carlo estimator。

若 control variate method 的 standard deviation 小於 ordinary Monte Carlo，表示此方法有效降低估計變異數，並使 95% confidence interval 變窄。整體而言，control variate method 能提升 Asian call option Monte Carlo pricing 的估計效率。

4. Pricing an American Put Option Using Longstaff-Schwartz Method

	n_paths	n_steps	price	sd	se	CI_lower	CI_upper	\
0	10000	50	0.446531	0.525003	0.005250	0.436241	0.456821	
1	50000	50	0.445862	0.531463	0.002377	0.441203	0.450520	
2	100000	50	0.443151	0.524497	0.001659	0.439900	0.446402	
3	10000	100	0.450625	0.543572	0.005436	0.439971	0.461279	
4	50000	100	0.445274	0.523110	0.002339	0.440689	0.449860	
5	100000	100	0.443738	0.525019	0.001660	0.440483	0.446992	
6	10000	252	0.443552	0.504658	0.005047	0.433660	0.453443	
7	50000	252	0.443236	0.513911	0.002298	0.438731	0.447740	
8	100000	252	0.443099	0.518705	0.001640	0.439884	0.446314	
9	10000	500	0.447785	0.516024	0.005160	0.437671	0.457899	
10	50000	500	0.442509	0.504602	0.002257	0.438086	0.446932	
11	100000	500	0.443594	0.510077	0.001613	0.440433	0.446756	
early_exercise_ratio								
0			0.33550					
1			0.32236					
2			0.32956					
3			0.29720					
4			0.34218					
5			0.32664					
6			0.40350					
7			0.34042					
8			0.34868					
9			0.38370					
10			0.35534					
11			0.36224					

American put 可以在到期日前提前履約。因此，在每個時間點都需要比較：

- Exercise Value
- Continuation Value

對 American put 而言：

$$\text{Exercise Value} = \max(K - S_t, 0)$$

若 Exercise Value 大於 Continuation Value，則選擇提前履約；否則繼續持有。

Stock Price Simulation

本題先在 risk-neutral measure 下模擬股價路徑：

$$S_{t+\Delta t} = S_t \exp \left[\left(r - \frac{1}{2} \sigma^2 \right) \Delta t + \sigma \sqrt{\Delta t} Z \right]$$

其中：

$$Z \sim N(0,1)$$

本題使用參數：

$$S_0 = 10, K = 10, r = 0.04, \sigma = 0.4, T = \frac{1}{12}$$

模擬路徑數為：

100000

時間切割數分別測試：

50,100,252,500

Longstaff-Schwartz Method

LSM 的核心概念為 backward induction。

在到期日，American put payoff 為：

$$\max(K - S_T, 0)$$

接著從倒數第二個時間點開始，逐期往前判斷是否應提前履約。

在每個時間點，只對 in-the-money paths 進行分析：

$$S_t < K$$

因為只有價內路徑才有提前履約的可能。

4.3 Estimating Continuation Value

對每個時間點的價內路徑，將未來現金流折現回當期，作為 dependent variable：

$$Y = \text{discounted future cashflow}$$

並使用當期股價 S_t 的二次多項式做 regression：

$$\text{Continuation Value} \approx a_0 + a_1 S_t + a_2 S_t^2$$

其中 regression basis functions 為：

$$1, S_t, S_t^2$$

此 regression 用來估計 continuation value，也就是若現在不履約、繼續持有 American put option 的估計價值。

Exercise Decision

在每個時間點，比較：

$$\text{Exercise Value} = K - S_t$$

與：

$$\text{Continuation Value}$$

若：

$$K - S_t > \text{Continuation Value}$$

則選擇提前履約。

若：

$$K - S_t \leq \text{Continuation Value}$$

則繼續持有。

完成 backward induction 後，將每條路徑最後決定的現金流折現回 $t = 0$ ，並取平均，即得到 American put option 的估計價格。

Simulation Results

模擬結果如下：

n_paths	n_steps	Price	Standard Deviation	Standard Error	95% CI	Early Exercise Ratio
10000	50	0.4465	0.5250	0.00525	[0.4362, 0.4568]	0.3355
50000	50	0.4459	0.5315	0.00238	[0.4412, 0.4505]	0.3224
100000	50	0.4432	0.5245	0.00166	[0.4399, 0.4464]	0.3296
10000	100	0.4506	0.5436	0.00544	[0.4400, 0.4613]	0.2972
50000	100	0.4453	0.5231	0.00234	[0.4407, 0.4499]	0.3422

n_paths	n_steps	Price	Standard Deviation	Standard Error	95% CI	Early Exercise Ratio
100000	100	0.4437	0.5250	0.00166	[0.4405, 0.4470]	0.3266
10000	252	0.4436	0.5047	0.00505	[0.4337, 0.4534]	0.4035
50000	252	0.4432	0.5139	0.00230	[0.4387, 0.4477]	0.3404
100000	252	0.4431	0.5187	0.00164	[0.4399, 0.4463]	0.3487
10000	500	0.4478	0.5160	0.00516	[0.4377, 0.4579]	0.3837
50000	500	0.4425	0.5046	0.00226	[0.4381, 0.4469]	0.3553
100000	500	0.4436	0.5101	0.00161	[0.4404, 0.4468]	0.3622

Result Analysis

從結果可以觀察到，不同 n_{steps} 與 n_{paths} 下的 American put price 都相當接近，大約落在：

$$0.442 \sim 0.451$$

之間，代表 Longstaff-Schwartz method 在本題中具有良好的穩定性。

(1) Effect of n_paths

當 n_{paths} 增加時，可以觀察到：

Standard Error ↓

例如：

當：

$$n_{paths} = 10000$$

時，standard error 約為：

$$0.005$$

而當：

$$n_{paths} = 100000$$

時，standard error 約下降至：

$$0.0016$$

這是合理的，因為 Monte Carlo estimator 的：

$$SE = \frac{s}{\sqrt{N}}$$

會隨著模擬路徑數增加而下降，因此 confidence interval 也會變窄。

(2) Effect of n_steps

當 n_{steps} 增加時，American option 可提前履約的時間點增加，因此 American put option 的價值理論上可能略微上升。

從結果可以觀察到：

$$n_{steps} = 50, 100, 252, 500$$

得到的價格皆相當接近，表示本題中的 LSM 已經收斂至穩定結果。

此外，early exercise ratio 約落在：

$$0.30 \sim 0.40$$

之間，代表 American put 在許多路徑下會選擇提前履約，這與 American put option 的特性一致。

(3) Stability of LSM

本題使用二次多項式：

$$1, S_t, S_t^2$$

作為 regression basis functions。

由結果可觀察到，在不同參數設定下，LSM 所估計的 American put price 都相當穩定，表示此 regression basis 已能有效估計 continuation value。

4.7 Conclusion

本題使用 Longstaff-Schwartz Least-Squares Monte Carlo method 定價 American put option。

由於 American option 可以提前履約，因此不能只考慮到期 payoff，而必須在每個時間點比較：

- Exercise Value
- Continuation Value

LSM 方法透過：

1. 模擬股價路徑
2. backward induction
3. regression estimation of continuation value

來決定最佳提前履約時點。

從結果可知：

- LSM 能穩定估計 American put option price；
- 當 n_{paths} 增加時，standard error 顯著下降；
- 不同 n_{steps} 下的價格結果相近，顯示模型已具有良好收斂性。

因此，Longstaff-Schwartz method 是一種有效且常用的 American option Monte Carlo pricing 方法。